

FIAP

CHALLENGE

PLUSOFT

SÃO PAULO, BRASIL

Informações do Grupo

- **Macirander** - RM551416 - 2TDSPF
- **Carlos** - RM97528 - 2TDSPX
- **Munir** - RM550893 - 2TDSPF
- **Kaique** - RM551165 - 2TDSPX
- **Vinicius** - RM98839 - 2TDSPX

Sumário

1. [Introdução ao Projeto](#)
2. [Reflexão por Etapas do Desenvolvimento](#)
 - a. [Sprint 1: Primeiros Passos e Definição de Arquitetura](#)
 - b. [Sprint 2: Desenvolvimento do Modelo de Previsão de Churn](#)
 - c. [Sprint 3: Implementação da Interface e Integração com Streamlit](#)
3. [Reflexão Geral sobre o Desenvolvimento](#)
 - a. [O Que Funcionou Bem](#)
 - b. [Dificuldades e Desafios](#)
 - c. [Principais Aprendizados](#)
 - d. [Mudanças Futuras para Projetos Semelhantes](#)
4. [Planos para o Futuro do Projeto](#)
 - a. [Expansão do Modelo](#)
 - b. [Inclusão de IA Generativa](#)
 - c. [Integração com IoT em Tempo Real](#)
5. [Conclusão](#)

Análise Crítica e Avaliação do Processo de Desenvolvimento e Apresentação do Projeto Final

Introdução ao Projeto

O projeto de previsão de churn com IoT e IA Generativa foi desenvolvido com o objetivo de identificar comportamentos de clientes que indicam a possibilidade de saída de uma empresa, utilizando técnicas de Machine Learning e dados simulados. Através de uma arquitetura baseada em IoT e IA, criamos uma aplicação prática para previsão de churn que oferece insights valiosos para retenção de clientes em diversos setores.

Abaixo, reflito sobre cada fase do projeto, com observações sobre os aspectos técnicos e aprendizados significativos.

Reflexão por Etapas do Desenvolvimento

Sprint 1: Primeiros Passos e Definição de Arquitetura

- **O que Funcionou:** A etapa inicial de definição de requisitos foi essencial para alinhar expectativas e estabelecer uma base sólida para o desenvolvimento. Isso incluiu decidir sobre o uso de tecnologias como scikit-learn para a parte de Machine Learning e Streamlit para a interface, proporcionando um bom ponto de partida.
- **Desafios Enfrentados:** No início, foi desafiador entender como integrar as várias camadas tecnológicas do projeto, como IoT, IA generativa e análise de churn. Definir uma arquitetura funcional e escolher as variáveis mais relevantes para prever churn com dados limitados demandou uma reflexão estratégica.
- **Aprendizados:** Essa fase ensinou a importância do planejamento. Decidir e testar protótipos simplificados foi essencial para o fluxo de trabalho, reduzindo a necessidade de retrabalho.
- **O Que Faria Diferente:** Em futuros projetos, eu planejo incluir revisões periódicas para ajustar a arquitetura conforme as exigências técnicas e funcionais mudam ao longo do desenvolvimento.

Sprint 2: Desenvolvimento do Modelo de Previsão de Churn

- **O que Funcionou:** A escolha de um classificador de floresta aleatória mostrou-se eficaz para a análise de dados tabulares de churn, com variáveis como Gasto Mensal e Interações com Suporte. O modelo atingiu uma precisão razoável, oferecendo previsões de churn bastante consistentes no contexto dos dados fictícios.
- **Desafios Enfrentados:** Uma limitação significativa foi o uso de dados fictícios, o que reduziu a capacidade do modelo de generalizar em cenários reais. Em um projeto mais robusto, a coleta de dados reais ou a utilização de dados sintéticos mais próximos da realidade enriqueceriam o processo.
- **Aprendizados:** A importância da qualidade dos dados foi um dos principais aprendizados. Trabalhar com dados limitados ressaltou como variáveis adicionais, como feedback de clientes ou histórico de compras, poderiam melhorar substancialmente o modelo.
- **O Que Faria Diferente:** Em projetos futuros, integraria mais fontes de dados e variáveis mais detalhadas para capturar um panorama mais completo do comportamento do cliente.

Sprint 3: Implementação da Análise de Sentimento com VADER Sentiment

- **O que Funcionou:** O uso do VADER Sentiment para análise de sentimentos foi eficaz na identificação de tendências de churn, considerando o feedback textual dos clientes. Essa análise proporcionou uma camada adicional de insights qualitativos ao modelo.
- **Desafios Enfrentados:** A análise de sentimento depende de dados textuais bem definidos, e a interpretação de emoções em textos pode ser subjetiva, especialmente em dados fictícios. Além disso, a ausência de dados de feedback reais limitou a precisão dos resultados.
- **Aprendizados:** O uso de análise de sentimento enriqueceu o modelo, permitindo considerar o comportamento emocional dos clientes. Aprendemos a importância de combinar dados quantitativos e qualitativos para uma visão mais completa.
- **O Que Faria Diferente:** Em um cenário real, seria ideal incorporar feedback de clientes em linguagem natural, permitindo ao VADER Sentiment trabalhar com dados mais representativos e melhorar as previsões.

Reflexão Geral sobre o Desenvolvimento

O Que Funcionou Bem

- **Uso de Ferramentas Acessíveis:** Ferramentas como scikit-learn e Streamlit foram essenciais para desenvolver rapidamente o modelo e a interface, acelerando o protótipo e facilitando o teste da aplicação.
- **Modularidade:** A divisão em Sprints com entregas específicas permitiu focar em cada componente do projeto, resultando em um desenvolvimento mais organizado.

Dificuldades e Desafios

- **Limitação de Dados Fictícios:** Como mencionado, o uso de dados fictícios limitou o potencial do modelo. A falta de dados reais dificultou a avaliação da robustez do sistema em situações práticas.
- **Integração de Componentes:** A integração entre as várias partes do projeto, especialmente a IA generativa para enriquecer os dados, foi um desafio devido à complexidade e necessidade de dados mais realistas.

Principais Aprendizados

- **Curadoria de Dados:** A importância de dados de qualidade se destacou em cada fase do projeto. Um modelo é tão eficaz quanto os dados que o alimentam, e variáveis adicionais aumentam a precisão e aplicabilidade.
- **Feedback Contínuo:** O processo iterativo ajudou a refinar o projeto ao longo das sprints, reforçando a importância de revisões frequentes para ajustar a arquitetura e as funcionalidades.

Mudanças Futuras para Projetos Semelhantes

Para futuros projetos, integraria mais revisões e ajustes de arquitetura baseados em feedbacks e validaria hipóteses com dados mais próximos da realidade. A incorporação de dados reais ou sintéticos mais detalhados seria uma prioridade para aumentar a precisão e a utilidade do modelo.

Planos para o Futuro do Projeto

Expansão do Modelo

- **Variáveis Adicionais:** Expandir as variáveis para incluir localização geográfica, faixa etária e histórico

de interações, aumentando a precisão e representatividade do modelo.

Inclusão de IA Generativa

- **Geração de Dados Sintéticos:** Usar IA generativa para criar dados sintéticos mais realistas, simulando cenários de churn variados e dando maior base para o treinamento do modelo.

Integração com IoT em Tempo Real

- **Automatização de Análises:** Implementar a coleta e análise de dados em tempo real, integrando o modelo com dispositivos de IoT para uma análise mais dinâmica e preditiva.

Conclusão

Esse projeto trouxe valiosos aprendizados sobre a integração de IoT, IA Generativa e análise preditiva, proporcionando uma visão ampla das possibilidades de retenção de clientes em um contexto de arquiteturas disruptivas. O projeto também destacou a importância de dados de qualidade, de uma arquitetura flexível e de uma interface intuitiva para usuários.

A experiência com essas tecnologias e metodologias reforça a relevância de arquiteturas disruptivas na análise

de comportamento e retenção de clientes, oferecendo um modelo que pode ser expandido e aplicado em diversos setores.